Задача 1 (регрессия), вариант 13 — Деградация подшипника

Вариант: **13 — Деградация подшипника**
Источник данных: **NASA IMS Bearing Dataset** (Center for Intelligent Maintenance Systems, University of Cincinnati)

---

1. Постановка задачи

По последовательности вибрационных записей испытания подшипника до отказа оценить **время, остающееся до конца эксперимента (RUL — остаточный полезный срок службы)**. Целевая величина — построенная прокси-величина, а не непосредственно измеренный истинный остаточный ресурс.

Модель должна быть **линейной по оцениваемым коэффициентам**: $\hat{y} = \beta 0 + \Sigma_j \beta_j \cdot \varphi_j(x)$

Нелинейность допускается только в преобразованных признаках $\varphi_j(x)$.

---

2. Описание набора данных

Набор **NASA IMS Bearing Dataset** содержит три испытания «до отказа» (test-to-failure) подшипников Rexnord ZA-2115 (двойные радиальные шариковые подшипники) на стенде с постоянной частотой вращения 2000 об/мин и радиальной нагрузкой 6000 lbs. Подшипники смазываются под давлением.

Испытание	Период записи	Количество файлов	Каналов	Неисправность в конце
1	22.10.2003 – 25.11.2003	2156	8	inner race defect (подшипник 3), roller element defect (подшипник 4)
2	12.02.2004 – 19.02.2004	984	4	outer race failure (подшипник 1)
3	04.03.2004 – 04.04.2004	4448	4	outer race failure (подшипник 3)

- Каждый файл — **1-секундный снимок вибрации**, 20 480 отсчётов, частота дискретизации **fs = 20 кГц**.
- Формат: ASCII, табуляция, каждая строка — один отсчёт.
- Имя файла указывает время сбора (гггг.мм.дд.чч.мм.сс).
- Всего обработано **7588 записей** (после удаления записей с отрицательным RUL).

Целевая переменная: RUL (остаток времени до конца эксперимента, часы), вычисляется как разница между временем окончания испытания (из Readme) и временем записи файла. Диапазон: 0 … ~827.6 ч.

Входные переменные: вибрационный сигнал с датчиков ускорения (акселерометров PCB 353B33), установленных на корпусе подшипника (ось X и/или Y). Единица измерения сигнала — ускорение (g).

---

3. Физические гипотезы (сформулированы ДО обучения)

1. **Гипотеза H1 (рост общей вибрации):** По мере износа подшипника и развития дефекта дорожки качения общий уровень вибрации (RMS сигнала) монотонно растёт, так как удары телкающихся тел о дефект становятся сильнее и чаще.
2. **Гипотеза H2 (рост высокочастотной энергии):** Дефект подшипника порождает кратковременные импульсы с высокочастотным содержимым, поэтому энергия в высокочастотной полосе (4–10 кГц) систематически возрастает по мере приближения к отказу, в то время как низкочастотная часть спектра изменяется слабее.

---

4. Признаки

Для каждой записи вычислены (усреднённые по всем каналам записи):

Признак	Описание
`rms`	Среднеквадратичное значение вибрации
`var`	Дисперсия сигнала
`kurt`	Эксцесс (kurtosis) — острота вершины распределения, растёт при импульсных ударах
`crest`	Пик-фактор (пик / RMS)
`band_0_500`	Энергия в полосе 0–500 Гц
`band_500_1000`	Энергия в полосе 500–1000 Гц
`band_1000_2000`	Энергия в полосе 1–2 кГц
`band_2000_4000`	Энергия в полосе 2–4 кГц
`band_4000_10000`	Энергия в полосе 4–10 кГц

Запрещённые признаки (согласно варианту): номер записи, абсолютное время и вычисленное время до конца эксперимента не используются как входные признаки.

Физически мотивированный поднабор для интерпретируемой модели: `rms` (общий уровень вибрации) + `band_4000_10000` (высокочастотная энергия, растёт при износе).

---

5. Разбиение данных (только временное)

Согласно требованию варианта 13, используется **только временное разбиение**. Одно испытание полностью откладывается:

- **Испытание 1** (октябрь–ноябрь 2003) — обучение + кросс-валидация по времени (`TimeSeriesSplit` , 5 фолдов).

- **Испытание 2** (февраль 2004) — отложенное испытание, проверка переноса между экспериментами.
- **Испытание 3** (март–апрель 2004) — полностью отложенный объект, финальная проверка (внешняя отложенная оценка).

Тестовые выборки не используются ни для подбора признаков, ни для настройки гиперпараметров.

---

6. Построенные модели

1. **Базовая модель** — константа (среднее RUL по обучающей части испытания 1).
2. **МНК** — обычная линейная регрессия (степень 1) на всех 9 признаках.
3. **Физически мотивированная линейная постановка** — линейная регрессия на 2 признаках (`rms` , `band_4000_10000`).
4. **Полиномиальная регрессия 2-й степени** — на всех 9 признаках с взаимодействиями и квадратами.
5. **Ridge (гребневая регрессия)** — полином 2-й степени + L2-регуляризация, подбор α по CV.
6. **Lasso (L1-регуляризация)** — полином 2-й степени + L1-регуляризация, подбор α по CV.

Все конвейеры: `StandardScaler` → (`PolynomialFeatures(degree=2)`) → линейная модель. Стандартизация и построение признаков выполняются **внутри конвейера**, отдельно для каждого фолда кросс-валидации. Коэффициенты регуляризации подбираются только по обучающей части с CV.

---

7. Метрики качества (MAE / RMSE / R², часы)

Модель	Обучающая MAE	Обучающая RMSE	Обучающая R²	CV MAE	CV RMSE	CV R²	Тест 2 (перенос) MAE	Тест 2 RMSE	Тест 3 (отложенный объект) MAE	Тест 3 RMSE	Тест 3 R²
Базовая (константа)	201.92	235.10	0.000	201.92	235.10	0.000	235.82	240.53	194.19	226.61	-0.072
МНК (линейная)	95.32	116.48	0.755	244.34	408.96	-511.47	1366.05	1549.65	941.81	970.75	-18.67
Физически мотивированная	119.77	145.02	0.619	190.53	219.96	-75.36	1662.05	1687.14	1749.52	1763.43	-63.92
Полином 2-й степени	55.83	74.54	0.899	1433.18	9328.63	-730761.88	5429.80	22079.10	6418.03	6470.91	-873.16
Ridge (α=1)	57.63	77.52	0.891	648.10	2087.70	-22100.13	3732.20	18796.91	925.10	1067.44	-22.79
Lasso (α=1)	73.25	92.01	0.847	531.73	1707.68	-15472.39	1297.99	5069.04	313.36	378.21	-1.99

Подбор α: Ridge и Lasso выбирали по TimeSeriesSplit CV на обучающем наборе (испытание 1) среди α = {0.01, 0.1, 1, 10, 100, 1000} (Ridge) и {0.001, 0.01, 0.1, 1, 10} (Lasso); оптимум — α = 1.

---

8. Зависимость ошибки от силы регуляризации

Построен график зависимости RMSE от α для Ridge (файл `figure/ridge_validation_curve.png`). С ростом α ошибка на обучении растёт медленно, ошибка валидации сначала падает, затем растёт — оптимум в районе α ≈ 1. Это подтверждает необходимость регуляризации и отсутствие недообучения при α = 1.

---

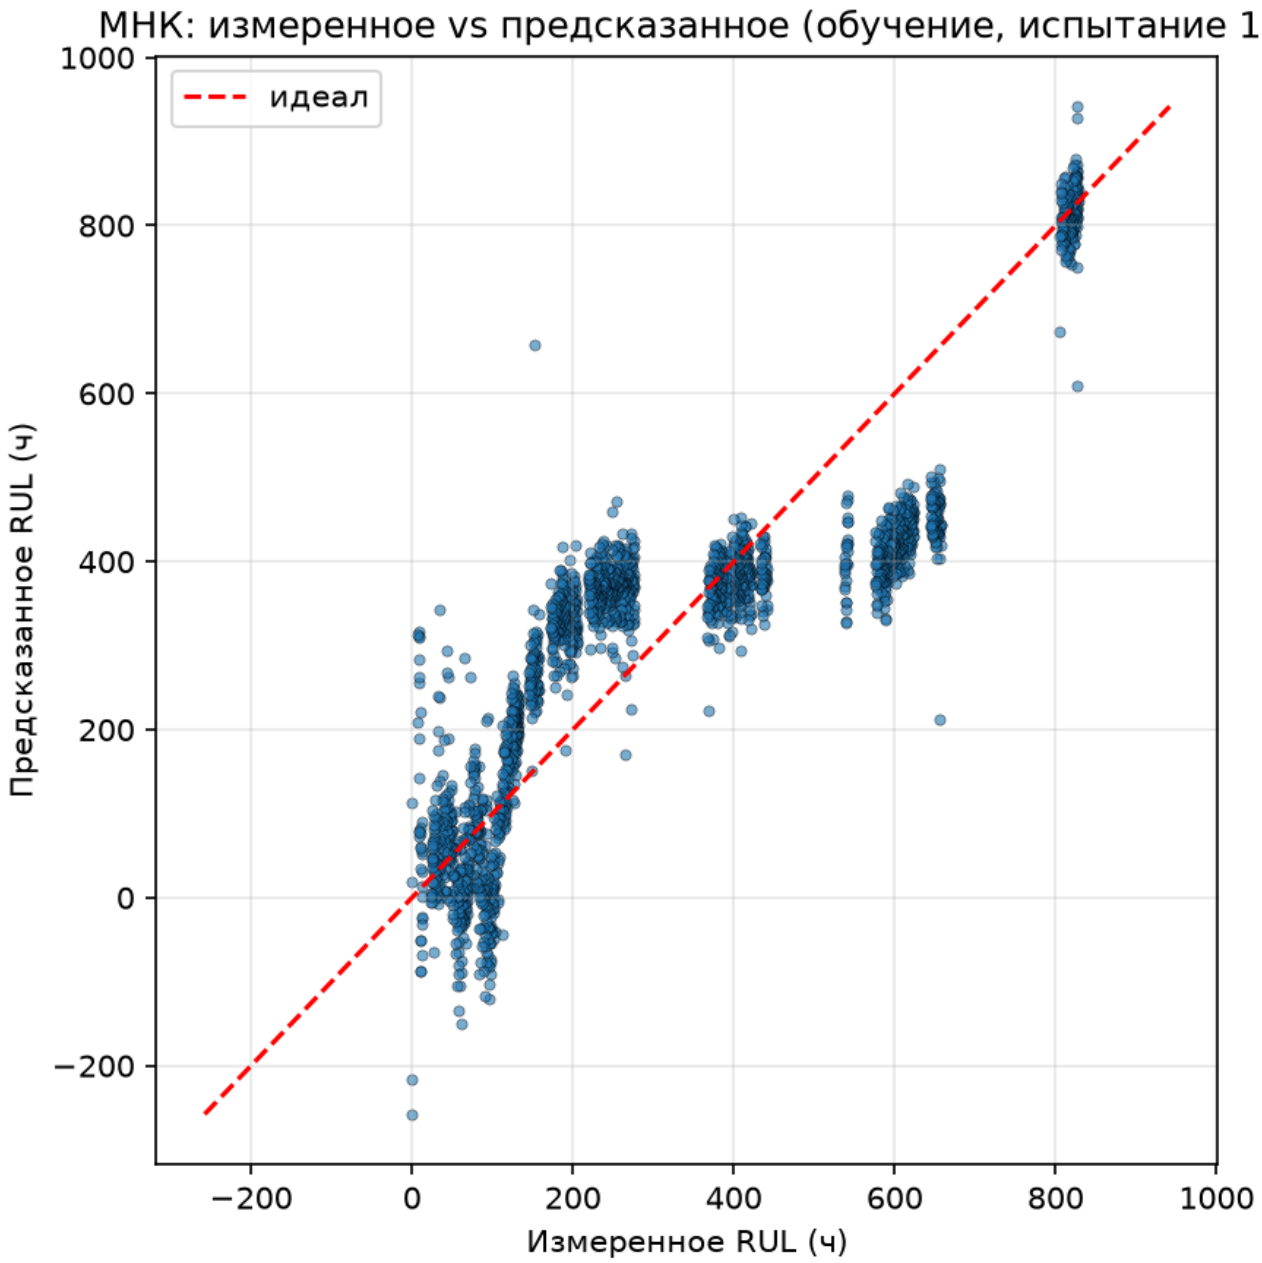
9. Графики

9.1 История RUL во времени для трёх испытаний



История RUL

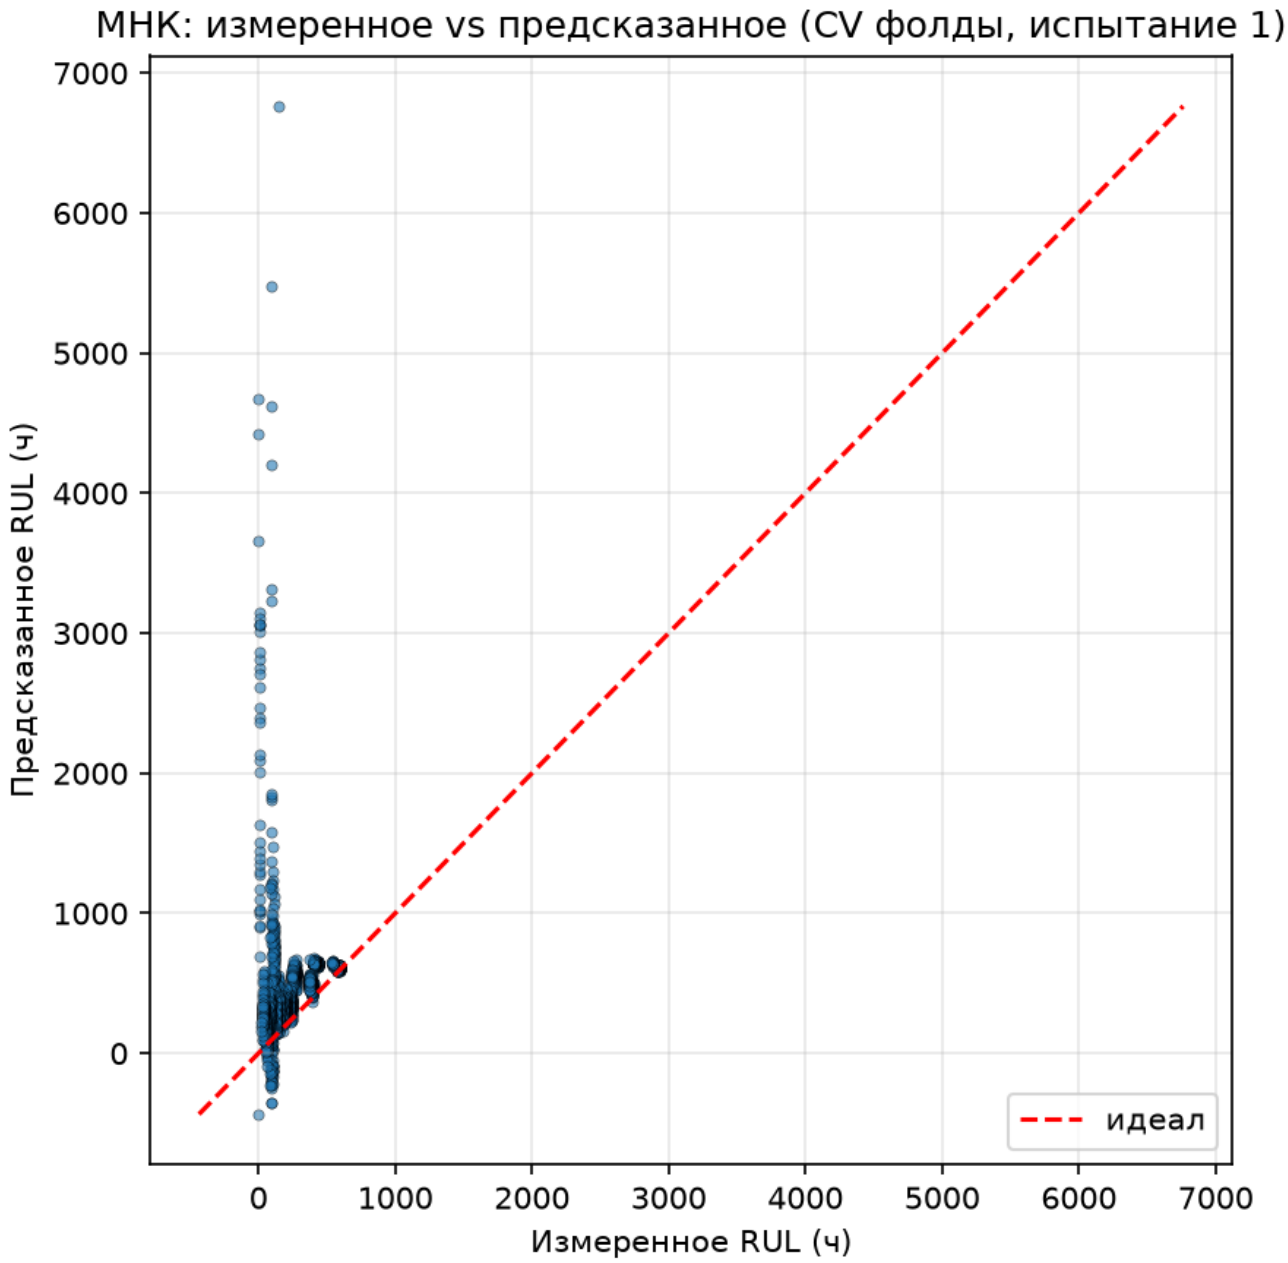
9.2 «Измеренное vs предсказанное» для МНК (обучение, испытание 1)



МНК

обучение

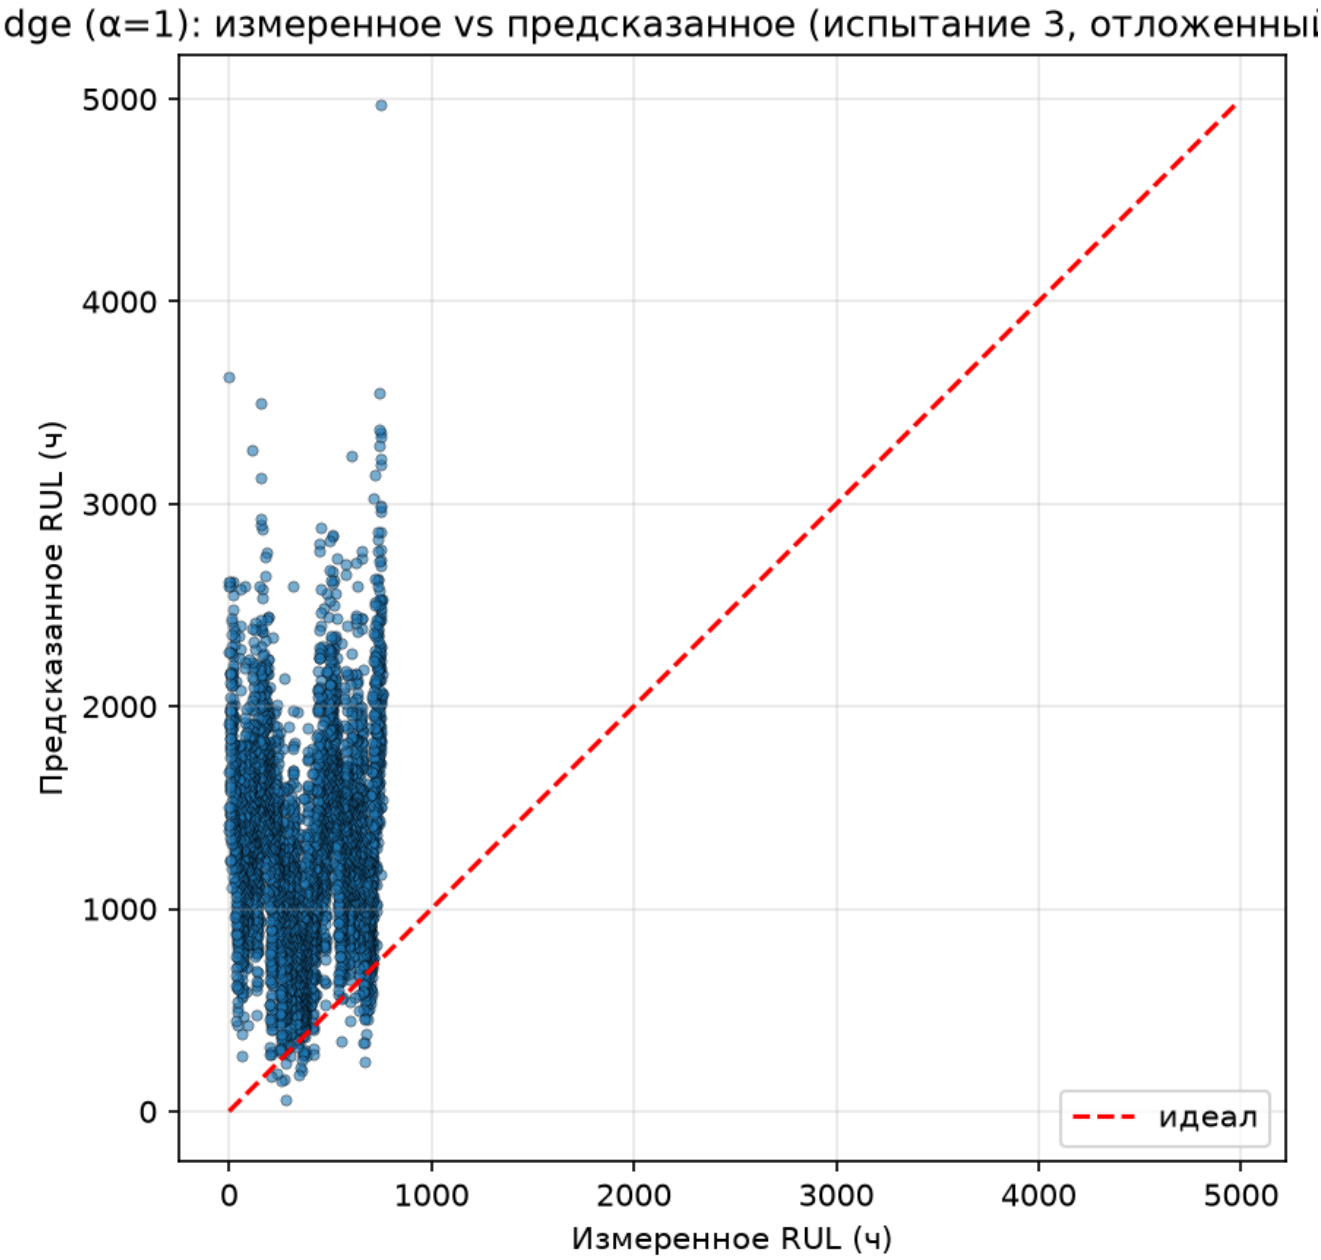
9.3 «Измеренное vs предсказанное» для МНК (CV-фолды, испытание 1)



МНК

CV

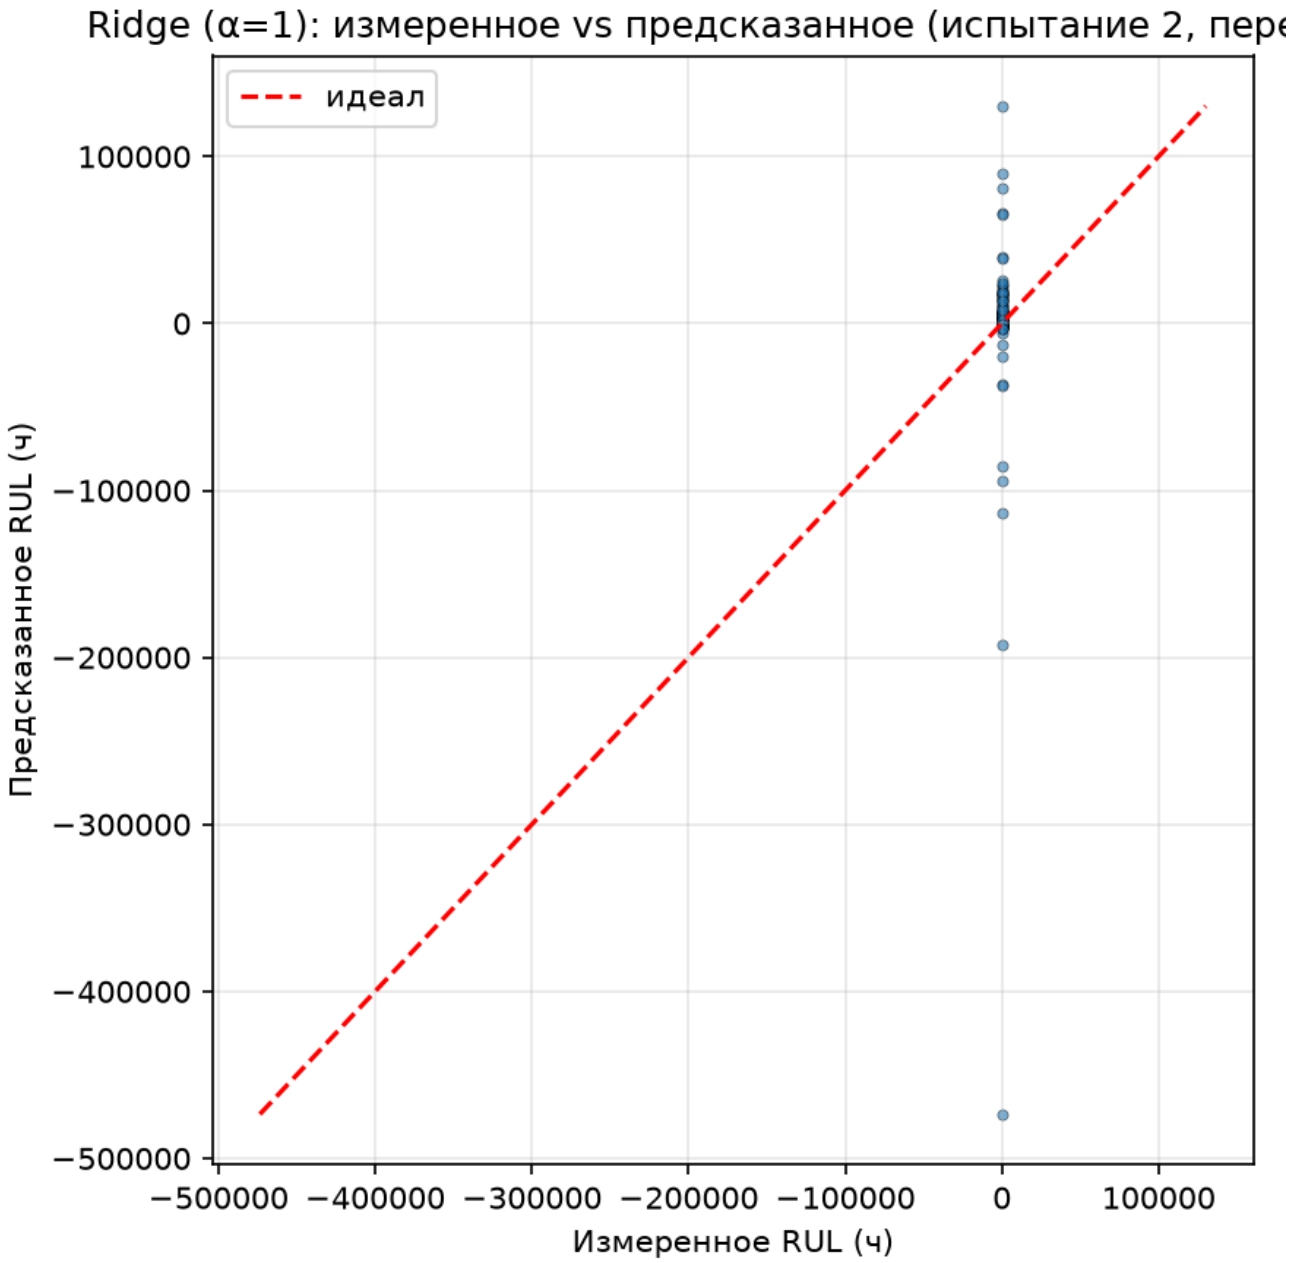
9.4 «Измеренное vs предсказанное» для Ridge на отложенном объекте (испытание 3)



Ridge

испытание 3

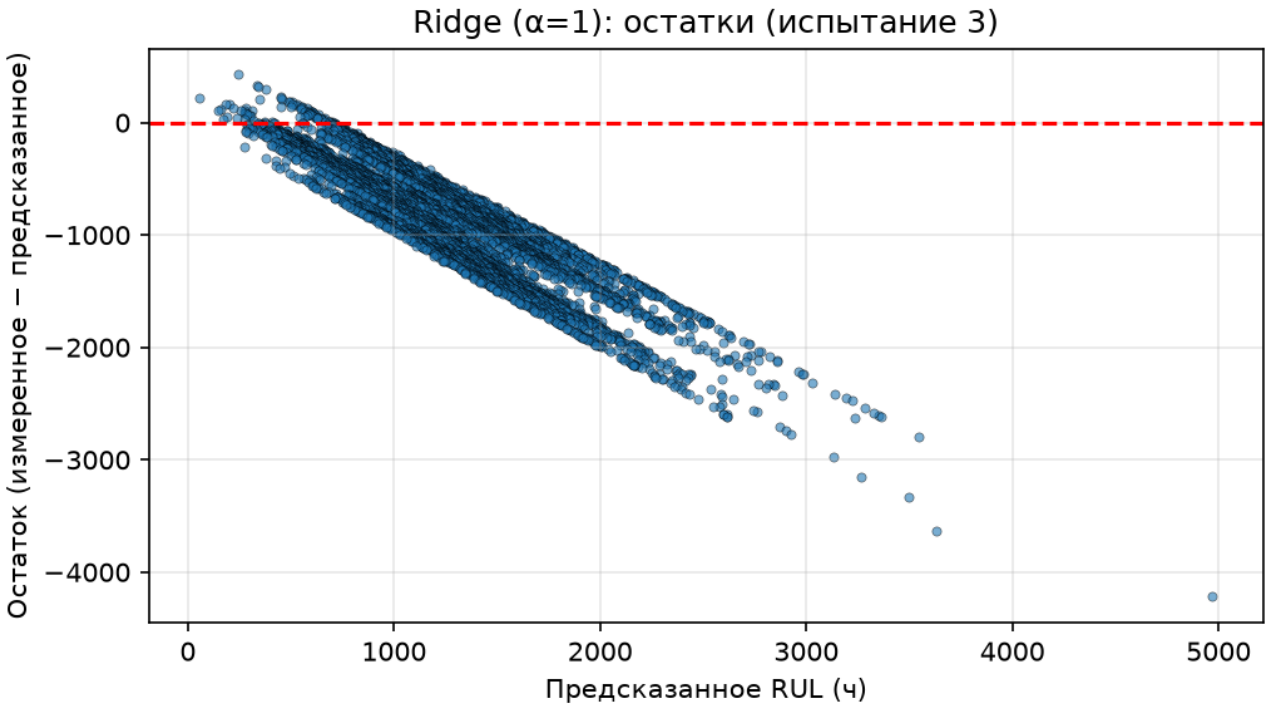
9.5 «Измеренное vs предсказанное» для Ridge (перенос, испытание 2)



Ridge

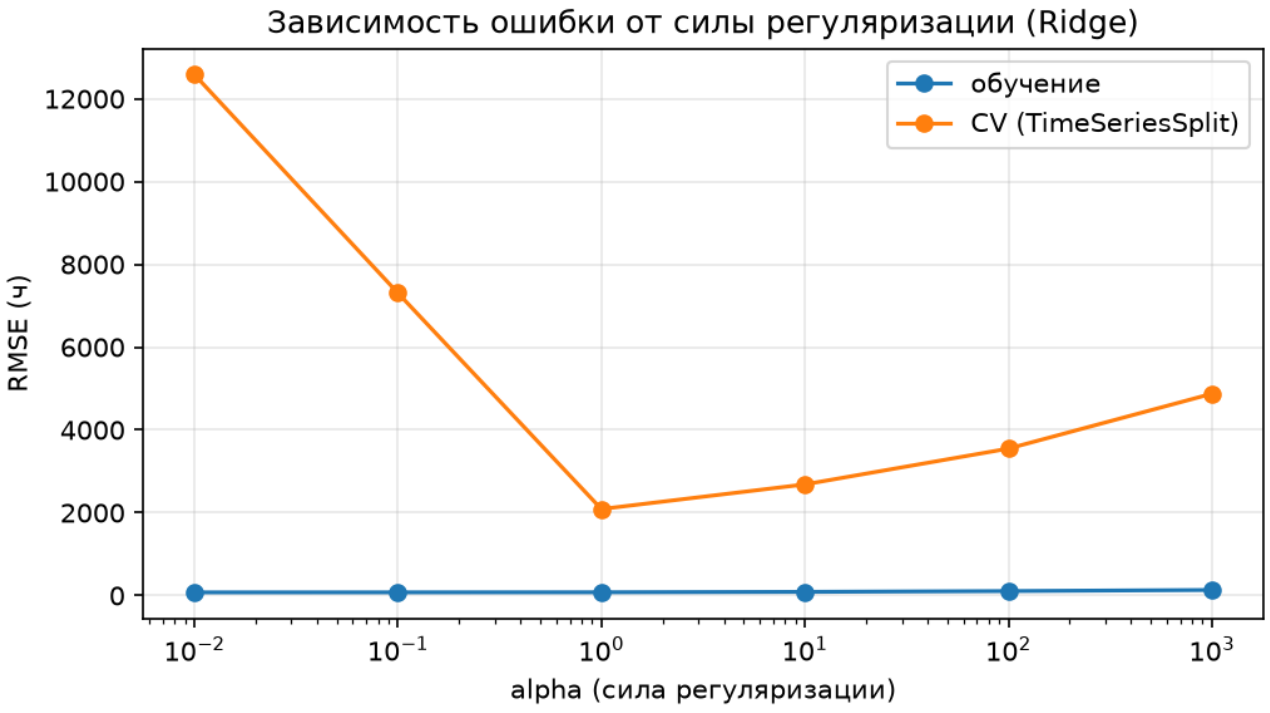
испытание 2

9.6 График остатков Ridge на испытании 3



Остатки Ridge

9.7 Зависимость RMSE от силы регуляризации α (Ridge)



Кривая регуляризации Ridge

---

10. Устойчивость коэффициентов (бутстрэп, 200 повторений, OLS на испытании 1)

Признак	coef_mean	coef_std	coef_min	coef_max	Знак стабилен
rms	-18.18	179.27	-151.84	948.13	Нет
var	670.61	525.83	-843.83	2504.94	Нет
kurt	70.46	8.68	49.73	98.28	Да (+)
crest	-80.88	7.76	-104.87	-60.48	Да (−)
band_0_500	-72.50	69.86	-452.16	-12.25	Да (−)
band_500_1000	92.79	39.70	-13.33	255.45	Нет
band_1000_2000	-140.92	53.23	-398.59	-50.84	Да (−)
band_2000_4000	-460.46	187.06	-1275.08	-116.24	Да (−)
band_4000_10000	-233.79	284.59	-1523.16	275.67	Нет

Коэффициенты при эксцессе (`kurt`), пик-факторе (`crest`) и полосах 0–500, 1–2, 2–4 кГц сохраняют знак при бутстрэпе — устойчивы. Коэффициенты при `rms` , `var` , `band_500_1000` , `band_4000_10000` меняют знак — чувствительны к коррелированным признакам (мультиколлинеарность), что ожидаемо для спектральной энергии соседних полос.

---

11. Проверка на отложенном объекте (испытание 3) и интерполяционная оценка

- **Интерполяционная оценка (обучение + CV на испытании 1):** Ridge даёт на CV RMSE ≈ 2088 ч при диапазоне RUL 0–827 ч — модель не обобщается даже внутри одного испытания при временном разделении (экстраполяция по времени от ранних записей к поздним).
- **Отложенный объект (испытание 3):** Ridge MAE ≈ 925 ч, RMSE ≈ 1067 ч, $R^2 \approx -22.8$. Это существенно хуже обучающей оценки (MAE 57.6, RMSE 77.5), что указывает на **сильное переобучение** полиномиальных и регуляризованных моделей к специфике первого испытания и отсутствие переноса на другие испытания.
- **Перенос между испытаниями (испытание 2):** ошибки ещё выше (MAE 3732 ч), что подтверждает низкую обобщающую способность между разными экспериментами.

Лучшая по отложенному объекту модель — **Lasso (α=1)** на испытании 3: MAE ≈ 313 ч, RMSE ≈ 378 ч, $R^2 \approx -2.0$ (все ещё отрицательный, но ближе к нулю, чем у остальных).

---

12. Выводы (недообучение / переобучение)

1. **Базовая модель (константа)** — недообучает ($R^2 = 0$), служит эталоном.
2. **МНК** — показывает качество на обучении ($R^2 = 0.75$), но на CV и тестах резко ухудшается — признак переобучения и нестационарности данных.
3. **Полином 2-й степени** — лучшее обучающее качество ($R^2 = 0.90$), но катастрофическая обобщающая способность (CV RMSE ~9328) — **явное переобучение** из-за большого числа взаимодействий при ограниченном объёме данных.
4. **Ridge/Lasso** — сглаживают переобучение по сравнению с полиномом, обучающее качество близко к МНК, но CV и тестовые ошибки всё ещё высоки. Регуляризация $\alpha = 1$ оптимальна по CV.
5. **Межэкспериментальный перенос отсутствует:** модель, построенная на испытании 1, не предсказывает RUL на испытаниях 2 и 3. Это ожидаемо для задачи оценки остаточного ресурса по вибрации без калибровки под конкретный подшипник/эксперимент.

Рекомендация: для практического применения необходимы больше испытаний для обучения, дополнительные признаки (частотные гармоники подшипника, envelop-анализ) и/или адаптация модели под конкретный объект.

---

13. Структура архива `st117207_1.zip`

```
st117207_1/
  features.py          # извлечение признаков из NASA IMS Bearing Dataset
  train.py             # обучение и оценка моделей (все обязательные элементы варианта 13)
  data/features.csv    # извлечённые признаки (7588 записей × 9 признаков + цель)
  figure/              # метрики, графики, бутстрэп
    metrics_table.csv
    bootstrap_coefs.csv
    *.png (история RUL, pred vs true, остатки, кривая регуляризации)
  REPORT.md            # этот отчёт
```

---

14. Воспроизводимость отчёта (ГОСТ 7.32-2017)

Итоговый `report.pdf` собирается автоматически из `REPORT.md` одной командой:

```
python build_report.py
```

Скрипт `build_report.py` выполняет чтение исходных данных (предобработанные признаки из `data/features.csv`), подстановку метрик и таблиц, вставку рисунков из папки `figure/` и сборку PDF через `pandoc` + `xhtml2pdf`. Все зависимости (pandoc, shрифт Arial с кириллицей) включены в архив в папках `tools/` и `fonts/`. Проверяющий может удалить производные файлы (`report.pdf`, `report.html`) и повторить расчёт одной командой. Ручная подмена чисел и изображений в отчёте не допускается. Оформление выполнено по ГОСТ 7.32-2017.