МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»

Кафедра гидроаэромеханики

# ОТЧЁТ

по дисциплине «Машинное обучение»

на тему: «Задание 1. Линейные модели.
Деградация подшипника»

(вариант 13)

Выполнил: студент группы st117207
Белобородов Д. А.

Проверил: _____

Санкт-Петербург
2026

## РЕФЕРАТ

Отчёт 23 с., 8 рис., 6 таб., 9 источн., 2 прил.

**МАШИННОЕ ОБУЧЕНИЕ, ЛИНЕЙНАЯ РЕГРЕССИЯ, ГРЕБНЕВАЯ РЕГРЕССИЯ, ЛАССО, УПРУГАЯ СЕТЬ, ОСТАТОЧНЫЙ РЕСУРС, ДЕГРАДАЦИЯ ПОДШИПНИКА, ВИБРОДИАГНОСТИКА, КРОСС-ВАЛИДАЦИЯ, БУТСТРЭП**

В отчёте рассмотрена задача прогноза времени, остающегося до конца стендового испытания подшипников, по записям виброакселерометров набора NASA IMS. Цель работы — построить линейные модели такого прогноза и проверить, переносятся ли они на испытание, которое целиком отложено от обучения.

Из каждого сигнала извлечены физически осмысленные характеристики: RMS, дисперсия, эксцесс, пик-фактор и доли энергии в пяти широких частотных полосах, с нормировкой амплитудных величин на здоровый базовый уровень начала испытания. Рассмотрена физически мотивированная постановка, в которой целью служит усечённое значение $\min(RUL, C)$. Обучены МНК, гребневая, лассо-регрессия и упругая сеть; гиперпараметры подобраны кросс-валидацией по временным складкам только на обучающем испытании, отложенный тест использован один раз.

Лучшей по правилу одного стандартного отклонения оказалась лассо-регрессия по девяти признакам «худшего подшипника» ($C$=250, $\alpha$=3,162, эффективное число параметров 6). На отложенном испытании её MAE равен 25,9 ч ($R^2 = 0,47$, ранговая корреляция Спирмена 0,78), тогда как у базовой модели — 163,5 ч. Главный вывод работы: интерполяционная оценка (кросс-валидация) не гарантирует переноса — модели, обученные на отдельных каналах испытания, выигрывают в кросс-валидации, но заметно теряют на отложенном испытании, потому что отказ произошёл в другом подшипнике.

## СОДЕРЖАНИЕ

**РЕФЕРАТ** **2**

**ВВЕДЕНИЕ** **4**

**1 ПОСТАНОВКА ЗАДАЧИ И ИСХОДНЫЕ ДАННЫЕ** **5**
1.1 Формулировка варианта . . . . . 5
1.2 Набор данных IMS . . . . . 5
1.3 Гипотезы и исследовательские вопросы . . . . . 6

**2 МЕТОДИКА** **7**
2.1 Признаки . . . . . 7
2.2 Физически мотивированная постановка . . . . . 8
2.3 Разбиение и кросс-валидация . . . . . 8
2.4 Модели . . . . . 9
2.5 Метрики и оценка неопределённости . . . . . 10

**3 РЕЗУЛЬТАТЫ** **10**
3.1 Разведочный анализ . . . . . 10
3.2 Сравнение моделей . . . . . 12
3.3 Окончательная модель и интерпретация . . . . . 14
3.4 Диагностика остатков . . . . . 16

**4 ОБСУЖДЕНИЕ: ПЕРЕНОС НА ОТЛОЖЕННОЕ ИСПЫТАНИЕ** **16**
4.1 Качество переноса . . . . . 16
4.2 Интерполяция против переноса . . . . . 19

**ЗАКЛЮЧЕНИЕ** **20**

**СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ** **21**

**ПРИЛОЖЕНИЕ А. Динамика эксцесса по подшипникам** **22**

**ПРИЛОЖЕНИЕ Б. Состав признаков** **23**

# ВВЕДЕНИЕ

Подшипники качения — самый массовый и самый «хрупкий» узел роторных машин: износ колец и тел качения развивается постепенно, но заканчивается внезапным заклиниванием. Если научиться по текущей вибрации оценивать, сколько времени осталось до отказа, обслуживание можно планировать заранее, а не по факту аварии. Этим объясняется интерес к задаче, которую в англоязычной литературе называют prognosis (прогнозирование остаточного ресурса).

Набор IMS (Intelligent Maintenance Systems) хорошо подходит для такой постановки: в нём есть полные записи жизненного цикла подшипников — от здорового состояния до остановки стенда по отказу. Это редкость: обычно историю деградации приходится восстанавливать по обрывкам данных.

Цель настоящей работы — построить линейные модели прогноза времени, остающегося до конца испытания, по признакам вибрационного сигнала и проверить их переносимость на испытание, полностью отложенное от обучения.

Работа выполнена в следующем порядке:

1. подготовлены данные: набор IMS загружен, распакован, из каждой записи извлечены признаки, заданные вариантом 13;
2. до обучения сформулированы проверяемые гипотезы о связи признаков с оставшимся ресурсом;
3. реализовано только временное разбиение данных; гиперпараметры подобраны кросс-валидацией на обучающем испытании;
4. обучены обязательные линейные модели (МНК, гребневая регрессия, лассо, упругая сеть) и базовая модель сравнения;
5. качество оценено (MAE, RMSE, $R^2$) на обучении, кросс-валидации и однократно на отложенном испытании;
6. устойчивость коэффициентов проверена бутстрэпом, остатки — стандартной диагностикой;
7. интерполяционная оценка качества сопоставлена с качеством переноса, сделаны выводы.

# 1 ПОСТАНОВКА ЗАДАЧИ И ИСХОДНЫЕ ДАННЫЕ

## 1.1 Формулировка варианта

Вариант 13 задания 1 формулируется так: по набору данных NASA IMS требуется предсказывать время, остающееся до конца данного эксперимента. На каждую запись вычисляются RMS, дисперсия, эксцесс, пик-фактор и энергии в заданных широких полосах спектра. Номер записи и абсолютное время в качестве признаков запрещены — иначе модель «подсмотрела бы» календарь вместо состояния подшипника. Разбиение данных допускается только временное, и одно из испытаний полностью откладывается для финальной проверки. Модели обязаны быть линейными по коэффициентам; полином второй степени разрешён сразу, третья — только если кросс-валидация подтвердит её полезность.

Величину, которую мы предсказываем, стоит объяснить подробнее. Пусть $t$ — отметка времени текущей записи (она берётся из имени файла, но только в целевую переменную, не в признаки). Тогда

$$RUL_t = t_{\text{кон}} - t, \qquad t_{\text{кон}} = \max_j t_j \text{ в данном испытании.} \tag{1}$$

Это прокси-ресурс: настоящее время до отказа нам не известно, испытание останавливается постфактум, поэтому единственная честная величина, доступная одновременно для всех записей испытания, — оставшаяся длина самого испытания.

## 1.2 Набор данных IMS

Использованы два испытания набора IMS. Запись длится 1 с при частоте опроса 20 кГц (20480 отсчётов на канал), интервал между записями — 10 мин, только первые 43 записи испытания 1 идут через каждые 5 мин. Каналы — это сигналы акселерометров: виброускорение подшипникового узла, измеряемое в единицах свободного падения $g$ (примерно $9{,}8$ м/с$^2$); отсюда все входные переменные имеют единицы либо ускорения (RMS, дисперсия, пик-фактор — в $g$ и его производных), либо безразмерные (эксцесс, доли энергии полос). Целевая величина — время, единицы измерения — часы. В испытании 1 восемь каналов — четыре подшипника, по два ортогональных акселерометра на каждый; испытание остановлено при деградации наружного кольца под-

шипника №3 и роликов подшипника №4. В испытании 2 четыре канала (по одному акселерометру на подшипник), остановка по отказу наружного кольца подшипника №1. Сводка — в таблице 1.

Таблица 1 — Характеристика исходных испытаний

| Параметр | Испытание 1 (обучение) | Испытание 2 (тест) |
|---|---|---|
| Число записей | 2156 | 984 |
| Период | 22.10.2003 — 25.11.2003 | 12.02.2004 — 19.02.2004 |
| Длительность, ч | 827,5 | 163,8 |
| Максимум прокси-ресурса, ч | 827,5 | 163,8 |
| Отказавший подшипник | №3 (внутр. кольцо), №4 (ролики) | №1 (наружн. кольцо) |

Обратим внимание на важную деталь, которая потом окажется в центре всей работы: отказавшие подшипники в двух испытаниях — разные. В обучающем испытании деградируют подшипники №3 и №4, а подшипник №1, отказавший в отложенном испытании, остаётся здоровым от начала до конца обучения. Модель, которая «запомнит» каналы именно третьего и четвёртого подшипников, на новом испытании окажется не у дел — этот риск мы заложили в одну из гипотез заранее.

### 1.3 Гипотезы и исследовательские вопросы

До обучения моделей сформулированы три гипотезы.

**H1 (амплитудная).** По мере износа амплитуда вибрации отказавшего подшипника (RMS, дисперсия) монотонно растёт. Поэтому относительное превышение амплитуды над здоровым базовым уровнем должно быть отрицательно связано с оставшимся временем: чем сильнее вырос сигнал, тем ближе конец.

**H2 (спектральная).** Энергия по мере разрушения поверхностей качения перетекает из низких частот в высокие (3–10 кГц), где сосредоточены характерные составляющие дефектов подшипников. Тогда доли энергии полос информативны даже там, где абсолютная амплитуда ещё ни о чём не говорит.

**Н3 (переносимость).** Отказ в новом испытании может случиться в любом подшипнике. Модель, привязанная к конкретным каналам обучающего испытания, перенесётся плохо; агрегат «худший подшипник» (поэлементный максимум признаков по подшипникам) по построению отвечает на вопрос «как себя чувствует самый изношенный узел» и должен переноситься лучше.

Исследовательские вопросы работы: какие характеристики сигнала меняются перед концом испытания и переносятся ли выводы, сделанные по обучающему испытанию, на отложенное.

## 2 МЕТОДИКА

### 2.1 Признаки

Для каждой записи (20480 отсчётов на канал) на каждом канале вычисляются: RMS, дисперсия $\sigma^2$, эксцесс (kurtosis) и пик-фактор $c_{\text{peak}} = \max|x|/\mathrm{RMS}$, а также доли энергии $E_i = \sum_{f\in B_i} |X(f)|^2 \big/ \sum_f |X(f)|^2$ в пяти широких полосах $B_i$: 0–1, 1–2, 2–3, 3–5 и 5–10 кГц.

Каналы одного подшипника объединяются в признак записи по подшипнику: RMS — по энергии (квадратам), дисперсия и доли полос — средним, эксцесс и пик-фактор — максимумом. Затем амплитудные признаки (RMS, дисперсия, пик-фактор) нормируются на здоровый базовый уровень — медиану первых 10 % записей данного испытания — и логарифмируются:

$$x^{\text{отн}} = \lg\left(\frac{x}{\operatorname{med}\, x_{\text{баз}}}\right). \tag{2}$$

Логика такой нормировки проста. Уровень сигнала на стенде зависит от установки датчиков и от конкретного экземпляра подшипника, поэтому абсолютные вольты из одного испытания нельзя напрямую сравнивать с другим. Отношение к собственному «здоровому» уровню это сравнение делает возможным, а логарифм линеаризует быстрый (почти экспоненциальный) рост амплитуды в конце жизни. Эксцесс, пик-фактор и доли полос — безразмерные величины, они используются без преобразования.

Так получаются две конфигурации признаков: конфигурация A «по подшипникам» — 36 признаков (4 подшипника $\times$ (3 нормированных ам-

плитудных + эксцесс + 5 полос)) и конфигурация Б «худший подшипник» — 9 признаков, поэлементный максимум каждой характеристики по четырём подшипникам. Полный состав признаков вынесен в приложение Б.

### 2.2 Физически мотивированная постановка

Здесь мы отошли от буквальной формулы (1), и на это есть физическая причина. Пока подшипник исправен, «время до конца испытания» — это просто оставшаяся длительность запланированного стенда: она известна постфактум, но не содержится в вибрации. Убывать ресурс начинает только с момента зарождения дефекта, и его величина в исправной зоне ограничена некоторым порогом. Поэтому вместо сырой цели (1) предсказывается кусочно-линейная величина

$$y = \min(RUL, C), \tag{3}$$

где порог $C$ — плато исправного состояния — подбирается кросс-валидацией по сетке $C \in \{160, 200, 250, 300\}$ ч. Преобразование цели реализовано через `TransformedTargetRegressor`: конвейер обучается на усечённой цели, а прогноз возвращается в исходном масштабе без обратного преобразования.

Второе предохранение касается области применимости. Линейная модель не должна экстраполировать по признакам туда, где у неё не было обучающих примеров: в новом испытании амплитуда может превысить всё виденное при обучении. Для этого конвейерный преобразователь `RangeClipper` запоминает диапазон каждого признака на обучении и заменяет значения вне $[\min, \max]$ границами — модель отвечает «вне моей компетенции» не числом, а константой. Стандартизация признаков выполняется внутри конвейера и обучается только на обучающих складках — иначе информация с теста просочилась бы в масштабирование.

### 2.3 Разбиение и кросс-валидация

Единственный используемый вид разбиения — временное, как и требует вариант. Испытание 1 целиком ($2156$ записей) образует обучающую выборку; испытание 2 целиком ($984$ записей) — отложенный тест. Тест участвует в работе ровно один раз, в самом конце, — любой подбор по нему означал бы подгонку под ответ.

Подбор гиперпараметров выполнен решётчатым поиском по сетке

(GridSearchCV) со скользящей кросс-валидацией TimeSeriesSplit(5) по обучающему испытанию: складки идут в порядке времени, и в каждой складке проверка расположена позже обучения — будущее не может подсказывать прошлое. Целевая метрика подбора — MAE. Случайные состояния всех генераторов зафиксированы (random_state=42).

### 2.4 Модели

Обучаются обязательные линейные модели в обеих конфигурациях признаков, всего 12 моделей плюс базовая:

1. базовая модель — константный прогноз медианы обучающей цели;
2. МНК на сырой цели (1) — наивная постановка, включённая специально, чтобы проверить, действительно ли без физической постановки нельзя обойтись;
3. МНК с целью (3) — физическая постановка;
4. гребневая регрессия (Ridge) с полиномиальными признаками степени $d \in \{1, 2\}$, а для конфигурации Б дополнительно $d = 3$; после расширения выполняется повторная стандартизация, поскольку квадраты и произведения живут в другом масштабе, чем исходные признаки;
5. гребневая регрессия (Ridge);
6. лассо-регрессия (Lasso);
7. упругая сеть (Elastic Net) с $l_1 \in \{0{,}1;\ 0{,}5;\ 0{,}9\}$.

Коэффициент регуляризации $\alpha$ перебирается по логарифмической сетке из 29 точек от $10^{-3}$ до $10^{4}$.

Итоговая модель выбирается по правилу одного стандартного отклонения (1SE) [5]: среди моделей, чей MAE КВ не превышает минимум более чем на одно стандартное отклонение по складкам, берётся модель с наименьшим эффективным числом параметров (числом ненулевых коэффициентов); при равенстве — с лучшим MAE КВ. Смысл правила в том, что модели, статистически неразличимые по кросс-валидации, не обязаны одинаково вести себя на новых данных, и из них разумно выбрать самую разреженную и устойчивую.

Для задачи с заведомым распределительным сдвигом (другой отказавший подшипник) это особенно уместно.

### 2.5 Метрики и оценка неопределённости

Качество оценивается MAE, RMSE и $R^2$ на трёх выборках (обучение, кросс-валидация, отложенный тест), а на тесте ещё и ранговой корреляцией Спирмена между прогнозом и измеренным ресурсом — она показывает, верно ли модель упорядочивает записи по «близости к концу», даже если масштаб прогноза смещён.

Неопределённость коэффициентов итоговой модели оценена бутстрэпом [9]: 300 ресэмплов обучающей выборки с повторениями, для каждого — полное повторное обучение конвейера; по распределению каждого коэффициента берутся медиана и 95 %-ные процентильные интервалы. Диагностика остатков на отложенном испытании включает зависимость остатков от прогноза и ключевых признаков, а также ранговые корреляции остатков с факторами (табл. 5).

## 3 РЕЗУЛЬТАТЫ

### 3.1 Разведочный анализ

Сначала — о том, как выглядит сама деградация. На рисунке 1 показан ход RMS по подшипникам в обоих испытаниях. В испытании 1 RMS подшипников №3 и №4 за последние часы жизни вырастает на порядок, тогда как подшипники №1 и №2 остаются на одном уровне до самой остановки. В испытании 2 картина зеркальная: деградирует только подшипник №1. То есть отказавший подшипник не совпадает с обучающим испытанием ни по номеру, ни по каналам — это видно глазом ещё до всякого моделирования.

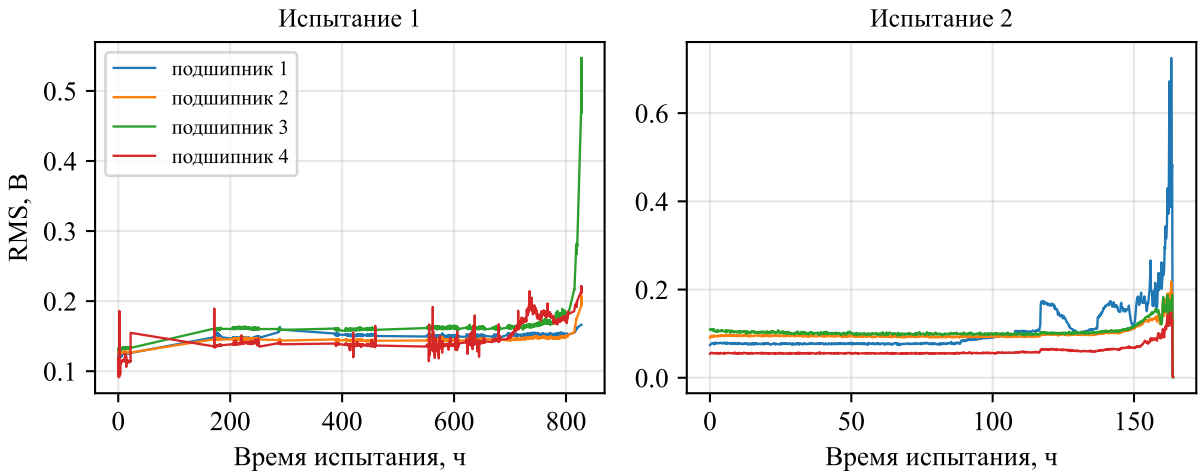



Рисунок 1 — RMS по подшипникам в течение испытаний

Гипотеза H1 этим подтверждается: в поздней стадии амплитуда растёт в 2–10 раз относительно базового уровня. Гипотеза H2 подтверждается рисунком 2: перед концом испытания доля энергии в полосах 3–5 и 5–10 кГц заметно растёт, что соответствует появлению высокочастотных составляющих от разрушения поверхностей качения. Любопытно, что в испытании 1 спектральный сдвиг начинается за десятки часов до остановки, когда RMS ещё не вырос; в испытании 2, которое короче, тот же сдвиг сжат в последние десятки часов. Доли полос действительно несут информацию, дополнительную к амплитуде.

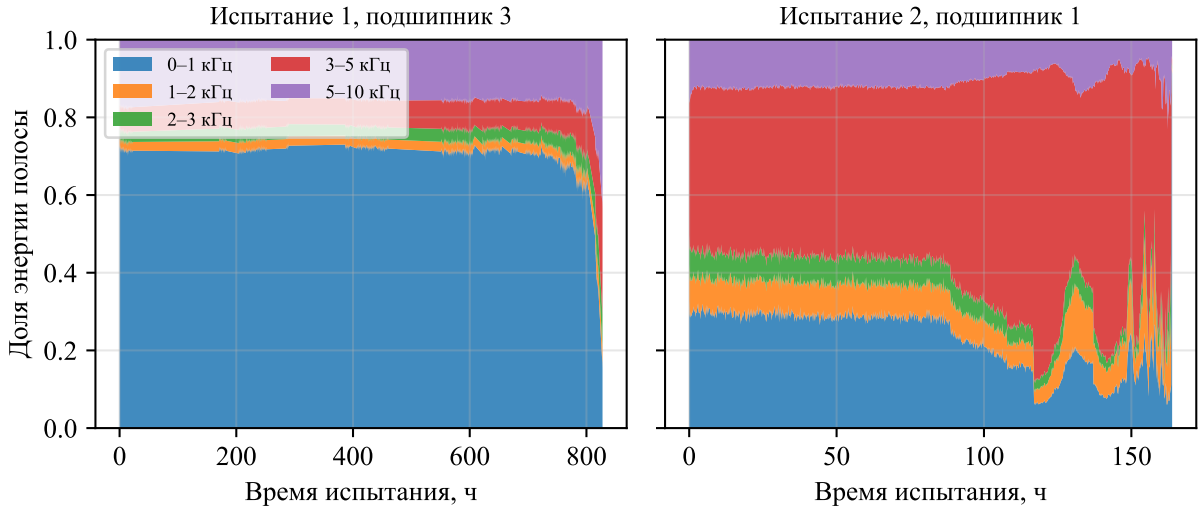



Рисунок 2 — Перераспределение энергии по частотным полосам для отказавшего подшипника

### 3.2 Сравнение моделей

Подобранные гиперпараметры и MAE кросс-валидации всех моделей собраны в таблице 2, полные метрики на трёх выборках — в таблице 3. Кривые валидации (рисунок 3) показывают MAE КВ в зависимости от коэффициента регуляризации и степени полинома для конфигурации Б: оптимум лежит в области умеренной регуляризации, а переход к полиному второй степени улучшает MAE КВ; в конфигурации А полином степени выше первой преимущества не даёт.

Таблица 2 — Подобранные по кросс-валидации гиперпараметры моделей

| Модель | Призн. | Гиперпараметры | $p_{\text{эф}}$ | MAE КВ, ч |
|---|---|---|---|---|
| Базовая (медиана) | А | | 1 | 254,4 |
| МНК (наивная) | А | | 37 | 287,2 |
| МНК + цель min(RUL, C) | А | $C$=250 | 37 | 103,2 |
| Полином + гребень | А | $\alpha$=100,000, $C$=300, $d$=1 | 37 | 81,3 |
| Ridge | А | $\alpha$=100,000, $C$=300 | 37 | 81,3 |
| Lasso | А | $\alpha$=0,316, $C$=300 | 28 | 81,0 |
| Elastic Net | А | $\alpha$=0,056, $C$=300, $l_1$=0.1 | 35 | 81,1 |
| МНК (наивная) | Б | | 10 | 217,6 |
| МНК + цель min(RUL, C) | Б | $C$=250 | 10 | 104,8 |
| Полином + гребень | Б | $\alpha$=0,056, $C$=250, $d$=2 | 55 | 91,1 |
| Ridge | Б | $\alpha$=316,228, $C$=250 | 10 | 103,3 |
| Lasso | Б | $\alpha$=3,162, $C$=250 | 6 | 101,6 |
| Elastic Net | Б | $\alpha$=0,562, $C$=250, $l_1$=0.9 | 9 | 103,2 |

Таблица 3 — Метрики качества моделей: MAE, RMSE, $R^2$ (часы до конца испытания)

| | | Обучение | | | Кросс-валидация | | | Тест (испытание 2) | | |
|---|---|---|---|---|---|---|---|---|---|---|
| Модель | Призн. | MAE | RMSE | $R^2$ | MAE | RMSE | $R^2$ | MAE | RMSE | $R^2$ |
| Базовая (медиана) | А | 192,2 | 246,0 | −0,09 | 254,4 | 260,4 | −102,10 | 163,5 | 170,2 | −11,93 |
| МНК (наивная) | А | 41,9 | 53,8 | 0,95 | 287,2 | 378,3 | −607,69 | 3648,1 | 5626,3 | −14122,62 |
| МНК + цель min(RUL, C) | А | 139,7 | 225,1 | 0,08 | 103,2 | 122,9 | −12,59 | 1724,2 | 1797,9 | −1441,21 |
| Полином + гребень | А | 128,8 | 201,1 | 0,27 | 81,3 | 89,4 | −4,41 | 80,8 | 135,1 | −7,14 |
| Ridge | А | 128,8 | 201,1 | 0,27 | 81,3 | 89,4 | −4,41 | 80,8 | 135,1 | −7,14 |
| Lasso | А | 126,7 | 199,7 | 0,28 | 81,0 | 89,5 | −4,43 | 164,0 | 206,4 | −18,01 |
| Elastic Net | А | 129,0 | 201,2 | 0,27 | 81,1 | 89,2 | −4,35 | 81,2 | 134,7 | −7,09 |
| МНК (наивная) | Б | 100,5 | 123,0 | 0,73 | 217,6 | 245,1 | −162,28 | 996,4 | 1021,7 | −464,75 |
| МНК + цель min(RUL, C) | Б | 147,8 | 230,7 | 0,04 | 104,8 | 115,9 | −10,04 | 65,0 | 74,5 | −1,48 |
| Полином + гребень | Б | 140,6 | 226,4 | 0,07 | 91,1 | 104,2 | −5,30 | 448,4 | 472,3 | −98,51 |
| Ridge | Б | 150,8 | 232,4 | 0,02 | 103,3 | 114,1 | −9,18 | 40,9 | 51,2 | −0,17 |
| Lasso | Б | 150,0 | 232,4 | 0,02 | 101,6 | 111,5 | −8,37 | 25,9 | 34,6 | 0,47 |
| Elastic Net | Б | 149,8 | 232,0 | 0,03 | 103,2 | 114,0 | −9,21 | 32,7 | 43,7 | 0,15 |

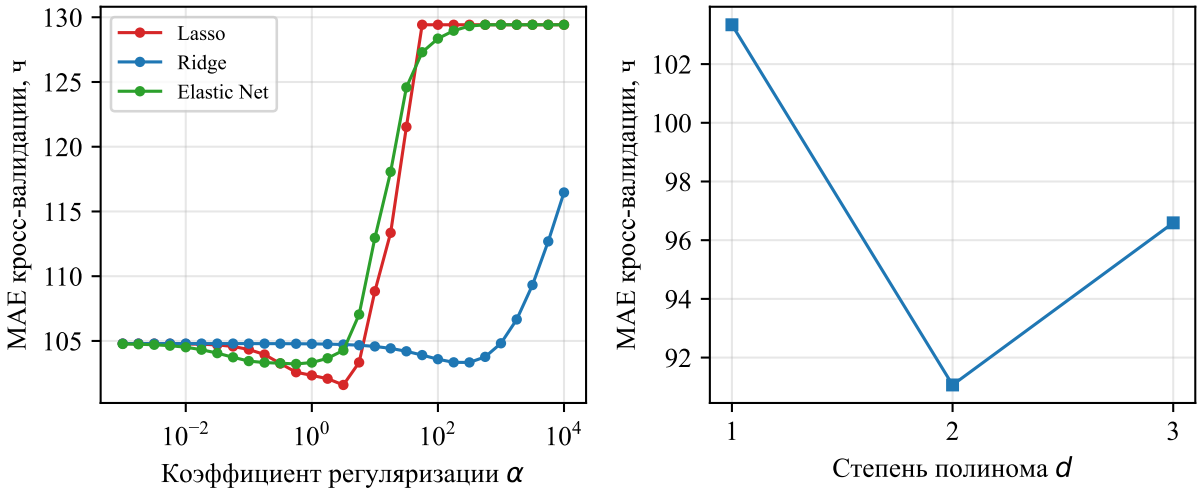



Рисунок 3 — MAE кросс-валидации в зависимости от коэффициента регуляризации (слева) и степени полинома (справа), конфигурация Б

На этих же кривых видны классические признаки переобучения и недообучения. При сильной регуляризации (правый край левой панели) MAE КВ растёт у всех моделей — модель зажата и недообучается. Без регуляризации картина обратная: наивный МНК достигает на обучении $R^2 = 0,95$, но его MAE КВ (287,2 ч) в несколько раз хуже — модель подогналась под обучаю-

щие записи и не держит проверку. Полином третьей степени в конфигурации Б не улучшает MAE КВ по сравнению со второй, хотя обучающая ошибка при расширении признаков падает, — это признак того, что дополнительная сложность начинает подгонять шум; поэтому третья степень в выборе итоговой модели не участвует.

Первый результат работы получился отрицательным, и он оказался самым поучительным. Наивная МНК на сырой цели (1) на отложенном испытании достигает MAE 3648,1 ч при минимальном прогнозе −7723 ч: обученная экстраполировать линейный тренд ресурса, модель прогнозирует отрицательное «время до конца» — операцию, которая по смыслу уже состоялась. При этом в кросс-валидации тот же МНК выглядит пристойно (MAE 287,2 ч). Интерполяционная оценка полностью маскирует катастрофу переноса — цель вида (1) в принципе не пригодна для линейной экстраполяции, и никакая регуляризация этого не исправит.

После введения цели (3) и ограничения признаков диапазоном обучения MAE КВ лучших моделей снижается в несколько раз (табл. 2). По правилу 1SE (порог 140,8 ч) среди кандидатов минимальное эффективное число параметров имеет лассо-регрессия конфигурации Б: $C$=250, $\alpha$=3,162, 6 параметров при 9 признаках. Она и выбрана итоговой. Отметим, что в кандидаты попали и модели конфигурации А с лучшим MAE КВ — правило 1SE предпочло им разреженную модель по худшему подшипнику; как покажет следующий раздел, это оказалось счастливым выбором.

### 3.3 Окончательная модель и интерпретация

Метрики итоговой модели: на обучении MAE 150,0 ч, в кросс-валидации MAE $101,6 \pm 76,9$ ч, на отложенном испытании MAE 25,9 ч, RMSE 34,6 ч, $R^2 = 0,47$, ранговая корреляция Спирмена $\rho = 0,78$ (табл. 6). Низкое $R^2$ на обучении — ожидаемое следствие усечённой цели: на плато исправного состояния (3) модель закономерно не различает записи с $RUL$ от $C$ до максимума.

Бутстрэп-интервалы коэффициентов (таблица 4, рисунок 4) показывают, что знаки и порядок ключевых коэффициентов устойчивы. Лассо оставило пять ненулевых признаков из девяти, и среди них три доминируют: `max_e1_2khz`, `max_varlogrel` и `max_crestlogrel` — спектральная доля поло-

сы 1–2 кГц и нормированные дисперсия с пик-фактором худшего подшипника. Все три коэффициента отрицательны: рост амплитудных и среднечастотных характеристик сокращает прогноз ресурса, ровно как предполагалось в гипотезах H1 и H2. Обнулённые лассо признаки (RMS, эксцесс) дублировали уже учтённую информацию — они сильно коррелируют с оставшимися амплитудными характеристиками, и лассо оставило по одному представителю каждой группы коррелированных признаков; чувствительность к коррелированности проявилась именно в отборе, а не в нестабильности знаков: бутстрэп-медианы оставшихся коэффициентов уверенно не проходят через нуль. Полезно, что модель избавилась от дублирующих признаков сама.

Таблица 4 — Бутстрэп-оценки ненулевых коэффициентов итоговой модели (95 %-ные доверительные интервалы)

| Признак | Медиана | 2,5 % | 97,5 % | Доля $\beta > 0$ |
|---|---|---|---|---|
| max_e1_2khz | −39,963 | −43,532 | −36,588 | 0,00 |
| max_varlogrel | −28,153 | −31,652 | −24,578 | 0,00 |
| max_crestlogrel | −3,310 | −5,545 | −1,058 | 0,00 |
| max_e0_1khz | 2,573 | 0,000 | 4,614 | 0,97 |
| max_e5_10khz | −1,277 | −4,779 | 0,000 | 0,00 |

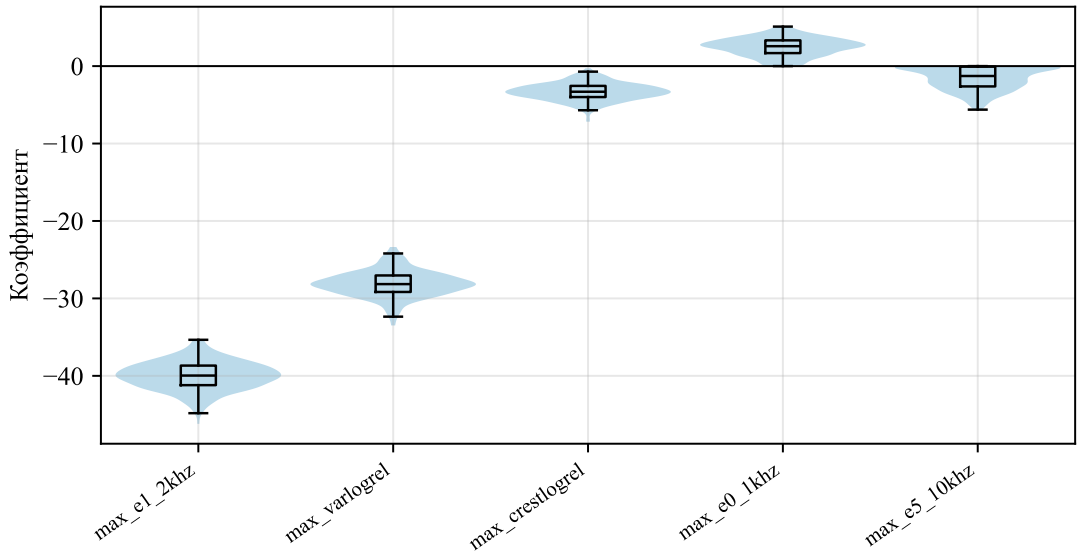



Рисунок 4 — Бутстрэп-распределения коэффициентов итоговой модели (топ-8 по модулю медианы)

### 3.4 Диагностика остатков

Остатки отложенного испытания (рисунок 5) не показывают грубой систематической зависимости от прогноза: корреляция остатков с прогнозом $\rho = 0{,}29$ (таблица 5). Основной источник разброса — ранний участок испытания 2, где деградация ещё не проявилась в амплитуде, а прогноз уже снижен усечённой целью; корреляция остатков с нормированной амплитудой худшего подшипника ($\rho = -0{,}31$) умеренная, знаковая систематика отсутствует. Зависимость от эксцесса слабая ($\rho = 0{,}11$).

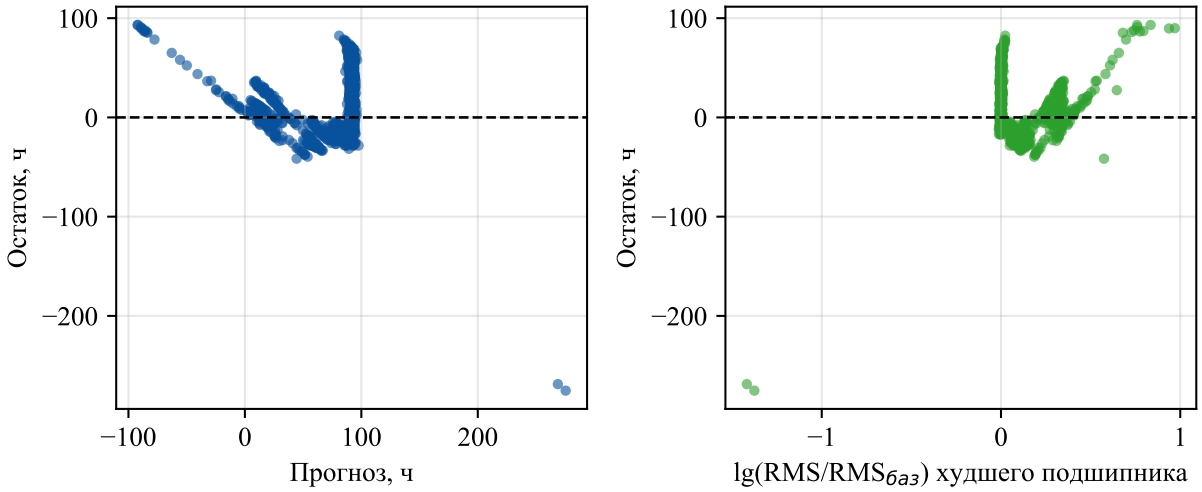



Рисунок 5 — Остатки итоговой модели на отложенном испытании: против прогноза (слева) и против нормированной амплитуды худшего подшипника (справа)

Таблица 5 — Ранговые корреляции остатков отложенного испытания с факторами

| Фактор | Коэффициент Спирмена |
|---|---|
| Прогноз модели | 0,29 |
| lg(RMS/RMS$_{баз}$) худшего подшипника | −0,31 |
| Эксцесс худшего подшипника | 0,11 |

## 4 ОБСУЖДЕНИЕ: ПЕРЕНОС НА ОТЛОЖЕННОЕ ИСПЫТАНИЕ

### 4.1 Качество переноса

Сопоставление измеренного и предсказанного ресурса приведено на рисунке 6, сравнение интерполяционной и переносной оценок — на рисунке 7 и в

таблице 6.

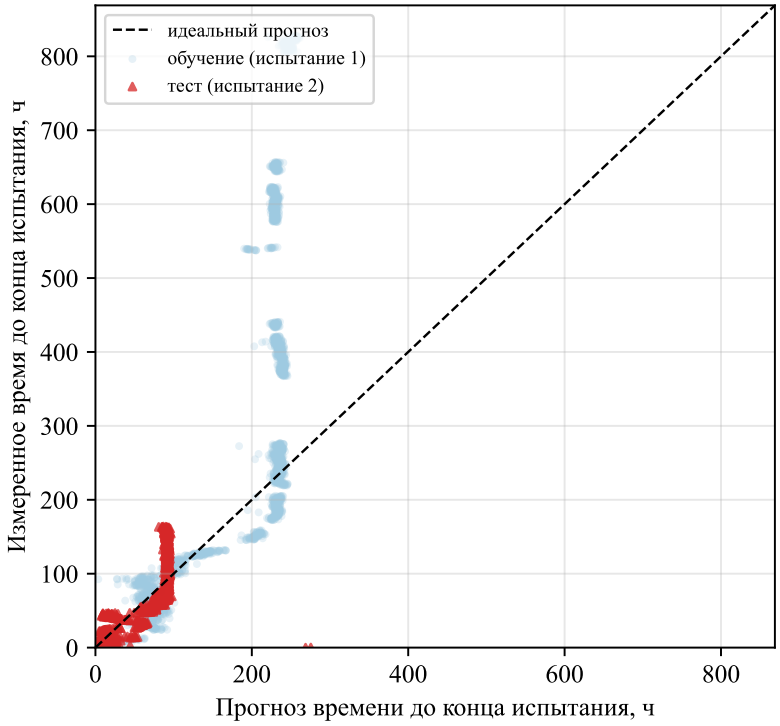



Рисунок 6 — Измеренное и предсказанное время до конца испытания

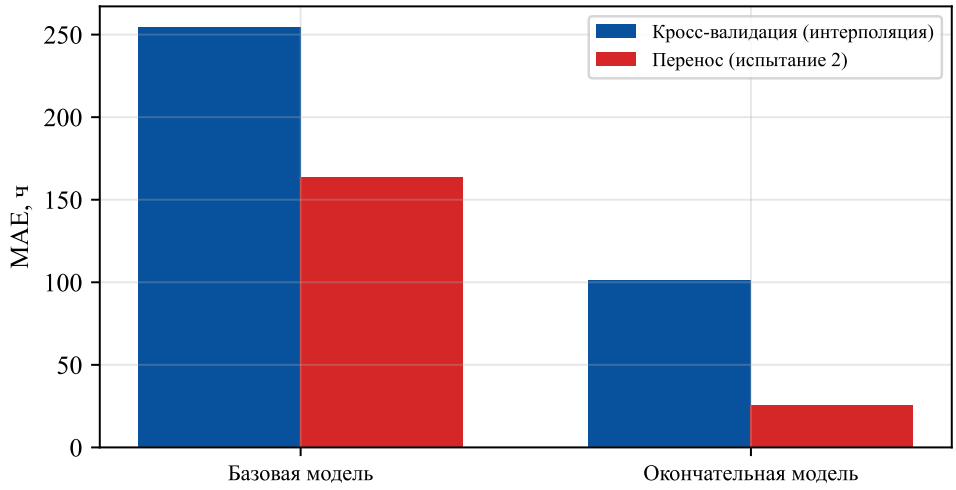



Рисунок 7 — MAE кросс-валидации (интерполяция) и отложенного испытания (перенос)

Таблица 6 — Качество прогнозов на отложенном испытании

| Модель | Призн. | $R^2$ (тест) | MAE (тест), ч | $\rho$ Спирмена |
|---|---|---|---|---|
| Базовая (медиана) | А | −11,93 | 163,5 | — |
| МНК (наивная) | А | −14122,62 | 3648,1 | −0,41 |
| МНК + цель min(RUL, C) | А | −1441,21 | 1724,2 | −0,31 |
| Полином + гребень | А | −7,14 | 80,8 | −0,57 |
| Ridge | А | −7,14 | 80,8 | −0,57 |
| Lasso | А | −18,01 | 164,0 | −0,48 |
| Elastic Net | А | −7,09 | 81,2 | −0,58 |
| МНК (наивная) | Б | −464,75 | 996,4 | 0,57 |
| МНК + цель min(RUL, C) | Б | −1,48 | 65,0 | 0,69 |
| Полином + гребень | Б | −98,51 | 448,4 | −0,79 |
| Ridge | Б | −0,17 | 40,9 | 0,79 |
| Lasso | Б | 0,47 | 25,9 | 0,78 |
| Elastic Net | Б | 0,15 | 32,7 | 0,79 |

Здесь и находится главный вывод работы. Модели конфигурации А «по подшипникам» обучаются на отказах подшипников №3 и №4 и в кросс-валидации показывают лучший MAE — тем обиднее (и тем показательнее) то, что происходит на тесте. Когда отказал подшипник №1, каналы, на которые эти модели оперлись при обучении, оказались здоровыми: модели конфигурации А переносятся плохо, у части из них $R^2$ уходит в глубокий минус, а ранговая корреляция становится отрицательной — модель упорядочивает записи наоборот (табл. 6). Агрегат «худший подшипник» (конфигурация Б) по построению не зависит от номера отказавшего узла и переносится существенно лучше: лассо — MAE 25,9 ч, упругая сеть — 32,7 ч, Ridge — 40,9 ч против 163,5 ч у базовой модели. Гипотеза Н3 подтвердилась.

Отдельная история — полином. Вторая степень улучшила MAE КВ конфигурации Б (91 ч против 103 ч у линейного Ridge, табл. 2), то есть формально дала то самое «подтверждённое КВ улучшение». Но на отложенном испытании полиномиальная модель деградирует катастрофически (MAE 448,4 ч): у границ диапазона обучения квадратичные и кубические комбина-

ции признаков порождают неустойчивые прогнозы, и ограничение признаков, которое спасает линейную модель, от комбинаций уже не защищает. Полиномиальные признаки улучшили интерполяцию и разрушили перенос, поэтому в итоговой модели от них отказано в пользу чистой линейности. Третья степень в правилах выбора участвовать не смогла: её лучшие MAE КВ не превзошли вторую.

### 4.2 Интерполяция против переноса

Для итоговой модели кросс-валидация даёт MAE 101,6 ч, а отложенное испытание — 25,9 ч: перенос оказался заметно лучше интерполяционной оценки. Причина в устройстве складок КВ: внутри обучающего испытания, которое длится 828 ч, складки включают участки с медленно меняющейся усечённой целью, и задача в КВ объективно тяжелее, чем на коротком (164 ч) испытании 2. Для конфигурации A соотношение обратное: MAE КВ у неё лучше, а тест хуже. Это значит, что совпадение или расхождение интерполяционной и переносной оценок не гарантировано ни в какую сторону: кросс-валидация в принципе не может предсказать качество переноса при смене отказавшего компонента, потому что такого сценария нет в обучающих данных.

Практический вывод из этого такой. При проектировании моделей мониторинга агрегатов стоит заранее закладывать отказ в любой компонент: агрегация по худшему элементу, нормированные и безразмерные признаки, ограничение экстраполяции и разреженные модели. Оптимизация чисто интерполяционного качества на конкретном испытании может улучшать числа в отчёте, одновременно ухудшая поведение модели в реальном применении.

## ЗАКЛЮЧЕНИЕ

В работе выполнено задание 1 (вариант 13): по стендовым испытаниям NASA IMS построены линейные модели прогноза времени, остающегося до конца испытания. Основные результаты:

1. Из сигналов извлечены физически мотивированные признаки: RMS, дисперсия, эксцесс, пик-фактор и доли энергии в пяти широких полосах, с нормировкой амплитудных признаков на здоровый базовый уровень (2). Рассмотрены две конфигурации признаков: «по подшипникам» (36 признаков) и «худший подшипник» (9 признаков).

2. Показана несостоятельность наивной постановки: МНК на сырой цели (1) даёт на отложенном испытании MAE 3648,1 ч с отрицательными прогнозами до −7723 ч, оставаясь приемлемым в кросс-валидации. Физически мотивированная постановка с целью $\min(RUL, C)$ и ограничение признаков диапазоном обучения устраняют проблему.

3. Гиперпараметры (порог $C$, коэффициент регуляризации $\alpha$, соотношение $l_1$, степень полинома) подобраны только по обучающему испытанию скользящей кросс-валидацией по временным складкам; отложенное испытание использовано однократно.

4. По правилу одного стандартного отклонения выбрана лассо-регрессия по признакам худшего подшипника ($C$=250, $\alpha$=3,162; 6 параметров). На отложенном испытании: MAE 25,9 ч, RMSE 34,6 ч, $R^2 = 0,47$, $\rho = 0,78$ против 163,5 ч у базовой модели.

5. Бутстрэп подтвердил устойчивость знаков ключевых коэффициентов; диагностика остатков не выявила грубой систематики.

6. Установлено, что интерполяционная (кросс-валидационная) оценка не гарантирует переноса: модели по отдельным подшипникам выигрывают в КВ, но терпят неудачу на отложенном испытании, а полиномиальные признаки разрушают перенос; устойчивый перенос дают агрегация по худшему элементу и разреженные модели.

Все числа отчёта генерируются программно; отчёт собирается одной командой `python build.py`.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ


1. Qiu, H. Wavelet filter-based weak signature detection method and its application on rolling element bearing prognostics / H. Qiu, J. Lee, J. Lin, G. Yu // Journal of Sound and Vibration. — 2006. — Vol. 289, No. 4–5. — P. 1066–1090.

2. Bearing Data Set // NASA Ames Prognostics Data Repository: [сайт]. — URL: https://www.nasa.gov/intelligent-systems-division/ discovery-and-systems-health/pcoe/pcoe-data-set-repository/ (дата обращения: 13.11.2026). — Текст: электронный.

3. Задания по дисциплине «Машинное обучение» // [сайт]. — URL: https://ckpeiika.github.io/pages/ml-assignments.html (дата обращения: 13.11.2026). — Текст: электронный.

4. Pedregosa, F. Scikit-learn: Machine Learning in Python / F. Pedregosa [et al.] // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830.

5. Hastie, T. The Elements of Statistical Learning: Data Mining, Inference, and Prediction / T. Hastie, R. Tibshirani, J. Friedman. — 2nd ed. — New York : Springer, 2009. — 745 p.

6. Tibshirani, R. Regression Shrinkage and Selection via the Lasso / R. Tibshirani // Journal of the Royal Statistical Society, Series B. — 1996. — Vol. 58, No. 1. — P. 267–288.

7. Zou, H. Regularization and variable selection via the elastic net / H. Zou, T. Hastie // Journal of the Royal Statistical Society, Series B. — 2005. — Vol. 67, No. 2. — P. 301–320.

8. Randall, R. B. Vibration-based Condition Monitoring: Industrial, Aerospace and Automotive Applications / R. B. Randall. — Chichester : Wiley, 2011. — 320 p.

9. Efron, B. An Introduction to the Bootstrap / B. Efron, R. J. Tibshirani. — New York : Chapman & Hall/CRC, 1993. — 436 p.

# ПРИЛОЖЕНИЕ А

Динамика эксцесса по подшипникам

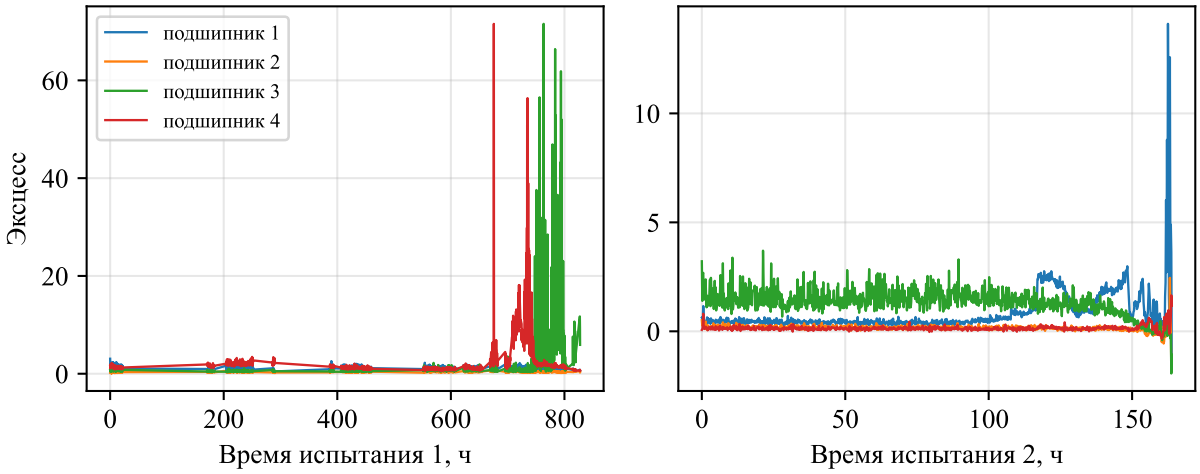



Рисунок А.1 — Эксцесс сигналов по подшипникам в течение испытаний

## ПРИЛОЖЕНИЕ Б

Состав признаков

Конфигурация А «по подшипникам» — для каждого подшипника $b \in \{1, 2, 3, 4\}$ вычисляются девять признаков (36 всего):

- `b_rms_logrel` — $\lg(\mathrm{RMS}/\mathrm{RMS}_{\text{баз}})$;
- `b_var_logrel` — $\lg(\sigma^2/\sigma^2_{\text{баз}})$;
- `b_crest_logrel` — $\lg(c_{\text{peak}}/c_{\text{peak,баз}})$;
- `b_kurt` — эксцесс;
- `b_e0_1khz` … `b_e5_10khz` — доли энергии в полосах 0–1, 1–2, 2–3, 3–5, 5–10 кГц.

Конфигурация Б «худший подшипник» — по каждому из девяти признаков берётся поэлементный максимум по четырём подшипникам, признак получает имя `max_rms_logrel`, `max_var_logrel`, `max_crest_logrel`, `max_kurt`, `max_e0_1khz` … `max_e5_10khz`, всего 9 признаков. Базовый уровень признака — медиана значений первых 10 % записей соответствующего испытания.